SVEUČILIŠTE U ZAGREBU FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 233

Parsiranje domenskih jezika koristeći Prattov parser

Marin Jovanović

Sadržaj

Uvo	od		
1.	Prat	tova tehnika parsiranja1	
1	.1.	Vrste parsiranja	
1	.2.	Od klasičnog pristupa do Prattove metode	
1	.3.	Obilježja Prattove metode	
1	.4.	Upravljanje greškama	
1	.5.	Poziv funkcija	
1	.6.	Ostali operatori	
2.	Prat	tova metoda naspram drugih	
3.	Prin	njena	
4.	Pred	Inosti i nedostatci	
Zak	ljučal	X22	
5.	5. Daljnji rad		
Lite	ratura	a	
Saže	etak		
Sun	nmary	7	
Skra	aćenio	ce	
Prog	Programska podrška28		

Uvod

Sve metode parsiranja se mogu svrstati u dvije kategorije: parsiranje od vrha prema dnu i parsiranje od dna prema vrhu. Prva metoda pokušava za zadani ulaz generirati strukturu (najčešće stablo, specifičnije apstraktno sintaksno stablo) tako što pokušava spojiti prvi token ulaza s nekom produkcijom gramatike. Na temelju prvotne produkcije pokušava se slijediti nadolazeće produkcije i spojiti ih s odgovarajućim tokenima i tako u konačnici izgraditi željenu strukturu. Drugi pristup je da se obrne prethodno opisani proces u nadi da će taj način biti povoljniji [1].

Vaughan Pratt je predstavio metodu koja spada u prvu skupinu te koristi prednost operatora, pa se stoga naziva parsiranje od vrha prema dnu uz prednost operatora.

Sve metode parsiranja se mogu svrstati u dvije kategorije: parsiranje od vrha prema dnu i parsiranje od dna prema vrhu. Prva metoda pokušava za zadani ulaz generirati strukturu (najčešće stablo, specifičnije apstraktno sintaksno stablo) tako što pokušava spojiti prvi token ulaza s nekom produkcijom gramatike. Na temelju prvotne produkcije pokušava se slijediti nadolazeće produkcije i spojiti ih s odgovarajućim tokenima i tako u konačnici izgraditi željenu strukturu. Drugi pristup je da se obrne prethodno opisani proces u nadi da će taj način biti povoljniji [1].

Vaughan Pratt je predstavio metodu koja spada u prvu skupinu te koristi prednost operatora, pa se stoga naziva parsiranje od vrha prema dnu uz prednost operatora.

1. Prattova tehnika parsiranja

1.1. Vrste parsiranja

Sve metode parsiranja se mogu svrstati u dvije kategorije: parsiranje od vrha prema dnu i parsiranje od dna prema vrhu. Prva metoda pokušava za zadani ulaz generirati strukturu (najčešće stablo, specifičnije apstraktno sintaksno stablo) tako što pokušava spojiti prvi token ulaza s nekom produkcijom gramatike. Na temelju prvotne produkcije pokušava se slijediti nadolazeće produkcije i spojiti ih s odgovarajućim tokenima i tako u konačnici izgraditi željenu strukturu. Drugi pristup je da se obrne prethodno opisani proces u nadi da će taj način biti povoljniji [1].

Vaughan Pratt je predstavio metodu koja spada u prvu skupinu te koristi prednost operatora, pa se stoga naziva parsiranje od vrha prema dnu uz prednost operatora.

1.2. Od klasičnog pristupa do Prattove metode

Metode se kompliciraju kada je za određeni token moguće primijeniti više produkcija, odnosno kada je moguće krenuti parsirati u različitim smjerovima u nadi da će jedan od tih smjerova biti valjan za zadani ulaz [1].

Mogli bismo formalno reći da je to problem pretraživanja stanja. Tada bi algoritme mogli ocjenjivati po tome koliko brzo pretražuju ta stanja te kakva im je kvaliteta intuicije, odnosno heuristike. Heuristika se može zadati već u samoj specifikaciji gramatike, ali je isto tako moguće natuknuti programu kojim putem ići pri samoj implementaciji. Za neke jednostavnije implementacije (jezike) nije teško odrediti kako bi se parser trebao ponašati i moguće je parsiranje odraditi na ad hoc način, ali kako jezik kojim se bavimo postaje složeniji tako i sam parser postaje kompliciraniji. Dobra praksa bi nalagala da kod bude dobro strukturiran i da slijedi određena pravila odnosno da nema odstupanja od nekakve globalne logike. Prattova tehnika upravo slijedi takav princip, on nudi generičko rješenje u koje mi usađujemo heuristiku, a generirano strukturu oblikujemo po želji.

Usmjerimo li pažnju na parsiranje od vrha prema dnu vrlo je vjerojatno da ćemo algoritam temeljiti na rekurzivnom spustu. Problem s kojim ćemo se možda susresti je lijeva rekurzija [3].

Prikažimo sada naivan pristup pri rješavanju takvog problema.

Recimo da postoji produkcija

```
S -> Sa | a
```

Očito je da će program uz iduću funkciju zaglaviti u rekurziji za neke ulaze (Kôd 1.1):

```
def S():

# TODO try
S()
a()

# TODO try if first production failed
a()

# TODO raise exception if both failed

Kôd 1.1 – neispravna funkcija S
```

Rješenje kojim bi mogli ovaj problem riješiti je iduće (Kôd 1.2):

```
def S():
    a()
    while True:
    # TODO break when following production can not be done
    a()
```

Kôd 1.2 – Ispravna funkcija S

Prethodno rješenje je valjano. Pratt je to rješenje poopćio i time dobio funkciju expression [3]. Kostur algoritma bazira se na temelju ovog članka¹, u kojem je prikazana inkrementalna izrada parsera. Poslužit ćemo se istom metodom i u ovom radu.

Tim poopćavanjem je zadovoljio dobru praksu, štoviše, učinio je da se cijeli parser fokusira na ovu (Kôd 1.3) funkciju. Uz pomoćne klase koje ćemo uvesti, prikazat ćemo veliku modularnost algoritma.

```
def expression(rbp=0):
    global token
    t = token
    token = lexer.__next__()
    while rbp < token.lbp:
        t = token
        token = lexer.__next__()
    left = t.nud(left)
    return left</pre>
```

Kôd 1.3 – Funkcija expression

Razlika ovog pristupa od onog opisanog u Kôd 1.2 je što se poopćava mehanizam vezan za lijevu rekurziju te više nije potrebno pisati isti dio koda svaki put kada se susretnemo s njom.

Ideja je da glavna funkcija expression pokuša spojiti trenutni (početni) token s tokenima s desne strane uz pomoć funkcije nud, ako to ima smisla, te nakon toga pokuša spojiti tokene koje je parser već prošao s trenutnim tokenom. Ta funkcionalnost se ostvaruje uz pomoć funkcije led te se kontrolira koliko će se ona puta zvati unutar petlje pomoću prednosti operatora. Primjeri će biti dani u idućem poglavlju.

Dio programa koji gradi tokene nećemo previše razmatrati u ovom radu. Možemo pretpostaviti da će funkcija lexer.__next__() vratiti objekt tokena koji bi trebao doći nakon trenutnog tokena, a u slučaju da ne postoji više tokena trebao bi se vratiti objekt TokenEOF koji simbolizira kraj izvornog koda kojeg želimo parsirati.

¹ https://eli.thegreenplace.net/2010/01/02/top-down-operator-precedence-parsing

Sada je potrebno dodati module koji će koristiti ovu funkciju, ona će njima upravljati i parsirati ih s obzirom na njihovu važnost (pomoću LBP i RBP, kasnije spomenutih).

1.3. Obilježja Prattove metode

Ono što je još potrebno definirati su klase tokena. Razmatrat ćemo jednostavni jezik koji će se sastojati samo od matematičkih operacija, varijabli i konstanti. To je primjer koji se većinom koristi kako bi se prikazala sva moć Prattove metode, pa tako i u članku² iz kojeg smo preuzeli kostur koda i nadogradili ga. Nadogradnjom smo željeli demonstrirati još neka zanimljiva svojstva i mogućnosti algoritma.

Razlog parsiranja samo matematičkog dijela jezika je intuitivna prednost operatora. Također je za primijetiti da veliki broj jezika koristi sličnu gramatiku za matematičke izraze, što je komponenta parsiranja koju je moguće odvojiti u posebnu rutinu parsera i onda parsirati posebno cijeli jezik, a kada se dođe do matematičkih izraza parsirati ih kao posebnu komponentu (kao zaseban dio jezika).

Prednost operatora u nekom izrazu (kodu) smatrat ćemo razrješava (spaja) li se neki token s tokenom ili tokenima desno od njega ili s tokenom ili tokenima lijevo od njega. Trivijalan i očigledan primjer je da ćemo izraz 1 - 2 * 3 razriješiti kao 1 - (2 * 3), a ne slijedno od lijeva na desno. Manje intuitivan primjer bi bio int x = 1;, ovdje bi puno teže bilo odrediti što ćemo smatrati lijevim, a što desnim spajanjem. O ovome će biti govora u poglavlju Prednosti i nedostatci.

U svrhu ove demonstracije gradit ćemo apstraktno sintaksno stablo, umjesto direktnog uvrštavanja i računanja izraza, kao što je rađeno u navedenom radu jer time možemo bolje razumjeti što se događa.

Kako bi mogli razlikovati tokene i ukalupiti logiku koja bi rekla na koji se način spaja određeni token poslužit ćemo se klasama. Prvi korak je napraviti klasu Token (Kôd 1.4) koju će svaka nova klasa tokena nasljeđivati.

² https://eli.thegreenplace.net/2010/01/02/top-down-operator-precedence-parsing

5

```
self.identifier = id
self.value = value
self.lbp = LBP.get(id)
self.rbp = RBP.get(id)

def nud(self):
    pass

def led(self, left):
    pass
```

Kôd 1.4 – klasa Token

Svaki token će imati svoju identifikacijsku oznaku identifier koja će biti istovjetna imenu klase, vrijednost value, težinsku vrijednost lijevog pridruživanja lbp (eng. left binding power) i težinsku vrijednost desnog pridruživanja rbp (eng. right binding power).

LBP i RBP predstavljaju dva rječnika koji će kao ključeve imati id tokena, a kao vrijednost samu vrijednost pridruživanja. Radi preglednosti dati ćemo ta dva rječnika kao tablicu (Tablica 1.1). Tokeni koji ne koriste svoju lbp i rbp vrijednost nisu prikazani u tablici, za njih možemo pretpostaviti da imaju vrijednost manju ili jednaku nula.

Tablica 1.1 LBP i RBP rječnici

LBP		RBP		
Token	Vrijednost	Token	Vrijednost	
		Subtraction	13	
Power	12			
Division	10			
Multiplication	10			
		Power	9	
Subtraction	8			
Addition	8			
		LeftBracket	7	
		Assignment	5	
Ternary	4			
Assignment	2			

	If	1
	I t	l

Također će svaki token morati implementirati svoju funkciju nud i led koja će nadjačati postojeće. Implementirat će te funkcije jedino ako ih koristi, za neke tokene jednostavno nema smisla nadjačavati jednu od njih. Primjere ćemo dati kasnije u radu.

Za navedeni primjer 1 - 2 * 3 potrebno je implementirati tri klase tokena; literale (Kôd 1.5), tokene za oduzimanje (Kôd 1.6) i množenje (Kôd 1.7). Valja primijetiti da token – ima i nud i led metodu jer se minus može naći prije i nakon drugih tokena. Također tvori sintaksni i semantički smisao.

```
class TokenLiteral(Token):
        def nud(self):
                return self.value
                           Kôd 1.5 – klasa TokenLiteral
class TokenSubtraction(Token):
        def nud(self):
                return [,,-,,, expression(self.rbp)]
        def led(self, left):
                return [,,-", left, expression(self.lbp)]
                         Kôd 1.6 – klasa TokenSubtraction
class TokenMultiplication(Token):
        def led(self, left):
                return [,,*", left, expression(self.lbp)]
```

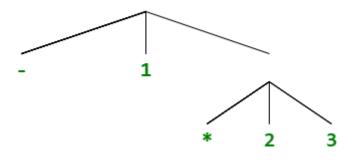
Kôd 1.7 – klasa TokenMultiplication

Potrebno je pozvati funkciju expression koja će imati zadanu vrijednost rbp jednaku 0. Prvo što će se dogoditi je da će se za token 1 nad klasom TokenLiteral zvati metoda nud koja će vratiti vrijednost 1. Nakon toga funkcija expression ulazi u while petlju u kojoj se zove za token – nad klasom TokenSubtraction metoda led koja vraća ["-", 1, expression(8)], za left se uzima vrijednost svega predano lijevo, što je samo broj 1, a za desni argument (zadnji element liste) vraća se expression(8) od kojeg očekujemo da vrati parsirani oblik (2 * 3).

Program ulazi u funkciju expression(8) i t.nud() vraća 2 te nakon toga ulazi u while. Unutar while-a zove se t.led(left) koja vraća ["*", 2, expression(10)].

Funkcija expression(10) za t.nud() vraća 3 te ne prolazi kroz while jer je trenutni token TokenEndOfFile koji nam govori da smo sve tokene iskoristili. Funkcija expression(10) tada vraća samo vrijednost 3.

Sada funkcija expression(8) može vratiti ["*", 2, 3] te se to ubacuje u početni expression() koji vraća ["-", 1, ["*", 2, 3]]. Takva struktura predstavlja AST koji možemo grafički prikazati (Slika 1.1).



Slika 1.1 AST za izraz 1 - 2 * 3

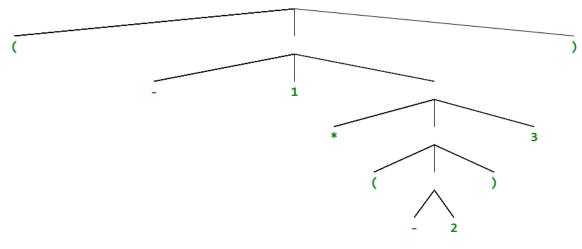
Idući korak bio bi implementacija upravitelja pogreškama. Sam kod nam djelom i nameće da razmišljamo o rubnim slučajevima odnosno, o ne-standardnom načinu parsiranja (odstupanju od zadanog). Primjer toga bi mogle biti zagrade, ali za to bi morali prvo uvesti dvije nove klase (Kôd 1.8 i Kôd 1.9).

class TokenLeftBracket(Token):

```
def nud(self):
    global token
    expr = expression(self.rbp)
    if not isinstance(token, TokenRightBracket):
        print(,,error right bracket")
        import sys
        sys.exit()
    r_b = token.value
    token = lexer.__next__()
    return [self.value, expr, r_b]
        Kôd 1.8 - klasa TokenLeftBracket
class TokenRightBracket(Token):
    pass
```

Kôd 1.9 – klasa TokenRightBracket

Zamislimo sada da parsiramo izraz (1 - (- 2) * 3). Kako bi to omogućili trebali bismo implementirati klasu lijeve i desne zagrade. Algoritam sada prvo uzima lijevu zagradu te nad njom zove metodu nud koja prvo zove funkciju expression(self.rbp). Ideja je da se sada isparsira sve unutar te zagrade i vrati se dio AST oblika ["(", expressiont(self.rbp), ")"]. Valja primijetiti ugniježđene zagrade koje će naš parser s lakoćom pravilno isparsirati. Ideja je da je vrijednost self.rbp veća od vrijednosti TokenRightBracket.lbp. Time osiguravamo da će se parsirati ulaz sve do prve desne zagrade. Ako postavimo pitanje što je s ugniježđenom zagradom odgovor je da je postupak isti. Ponovno će se krenuti parsirati izraz unutar zagrada sve dok ne naiđe na prvu desnu zagradu. U ovom slučaju vratit će se ['(', ['-', '2'], ')']. Taj će izraz vratiti expression funkciji koju je pozvala prva lijeva zagrada te će ona vratiti ['-', '1', ['*', ['(', ['-', '2'], ')'], '3']]. Nakon toga sve skupa vraća AST oblika ['(', ['-', '1', ['*', ['(', ['-', '2'], ')'], '3']], ')'] (Slika 1.2).



Slika 1.2 AST za (1 - (-2) * 3)

Zanimljivost ovog načina rješavanja zagrada je što možemo lako različite vrste zagrada tretirati isto, potrebno je samo pri stvaranju objekta definirati vrijednost self.value.

U ovom primjeru se za token – pozivala metoda nud, a ne led. Razlog ovoga je što je to bio prefiks broju 2, a nije se oduzimao 2 od nekog drugog broja. Možemo vidjeti kako se u ovom slučaju parsirao broj desno od tog tokena, a to je upravo 2. To je tako jer se zvala funkcija expression s vrijednosti 13 koji je maksimalan u našoj tablici, a to onda osigurava da se neće izvršiti while petlja u toj funkciji i vratit će samo nud koji odgovara broju 2. Ovaj primjer je moguće poopćiti: kada je potrebno da neki token vrati token koji je njemu s desna to je ostvarivo tako da se pozove funkcija expression s argumentom većim od svih vrijednosti lbp. Naravno, ako taj token u svojoj nud metodi zove ponovo funkciju expression onda će se i to morati razrješavati, ali uvijek će se vratiti samo vrijednost tog nuda, neće se izvršavati while dio tog expressiona.

Sada bi se moglo postaviti pitanje zašto se isto nije odradilo za desnu zagradu i odgovor se nalazi u upravljanju greškama, ali i optimizaciji. Puno je lakše odmah provjeriti je li idući token desna zagrada, i onda upravljati daljnjim tijekom ovisno o odgovoru, nego da se poziva funkcija expression koja će vratiti samo jedan token i te bi onda opet morali provjeriti je li vraćena desna zagrada.

1.4. Upravljanje greškama

U ovom primjeru gdje očekujemo desnu zagradu mogli bismo ispisati informaciju o grešci i probati nastaviti s parsiranjem. Ako pretpostavimo da pokušavamo parsirati neki izvorni kod i ustanovimo da bi negdje trebala postojati zagrada, a nje nema, mogli bismo ispisati poruku i svejedno nastaviti program kao da je idući token bila odgovarajuća zagrada. Tada bi nastavili s parsiranjem i mogli ustanoviti postoji li još koja pogreška u semantici koda. Za to bi trebali proširiti kod klase tokena za lijevu zagradu (Kôd 1.10).

```
class TokenLeftBracket(Token):

def nud(self):

global token

expr = expression(self.rbp)

if not isinstance(token, TokenRightBracket):

print("error right bracket")

#TODO determinate which type of bracket is needed

r_b = "err)"

else:

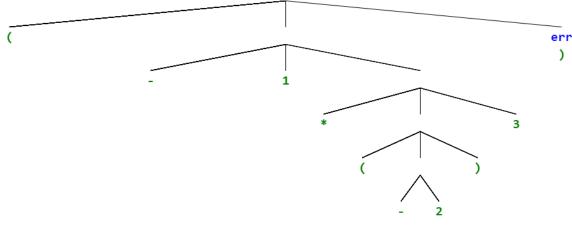
r_b = token.value

token = lexer.__next__()

return [self.value, expr, r_b]

Kôd 1.10 - klasa TokenLeftBracket
```

Iz metode nud makli smo dio koji prekida program i dodali TODO u kojem je potrebno utvrditi na temelju lijeve zagrade (self.value) koja bi zagrada trebala doći s desne strane. To je lako napraviti ako je poznato koje sve vrste zagrada mogu doći s lijeve strane. U ovom primjeru smo dali fiksnu vrijednost "err)" kako bi se bolje prepoznalo u ispisu stabla. Nismo pridijelili tokenu novu vrijednost putem funkcije lexer.__next__() jer je već vrijednost tokena iduća vrijednost. Ispis stabla je prikazan u nastavku (Slika 1.3) za ulaz (1-(-2*3).



Slika 1.3 AST za (1 - (-2 * 3)

Moglo bi se sada zapitati kako za izraz 1 + (2 - (3 + 4)) ustanoviti je li 1 + (2 - (3) + 4) ili 1 + (2 - (3 + 4)) i odgovor na to ovom metodom ne možemo dati, ali je ovim pristupom osigurano parsiranje ovog dijela izvornog koda bez ispadanja programa što nam je dovoljno. Programer će dobiti obavijest o grešci i sam će utvrditi na kojoj poziciji nedostaje desna zagrada.

1.5. Poziv funkcija

U sklopu jednog kalkulatorskog jezika imalo bi smisla dodati pozive trigonometrijskih funkcija. Pozivi funkcija u drugim (stvarnim) jezicima su slični pa bi se iz ovog primjera (Kôd 1.11) mogli iskonstruirati svi drugi pozivi funkcija. Stoga ovo smatramo vrijednim primjerom.

```
class TokenTrigonometry(Token):
    def nud(self):
        globa token
    if not isinstance(token, TokenLeftBracket):
        print(,,error left bracket")

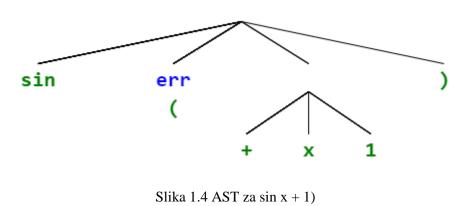
#TODO determinate which type of bracket is needed

1_b = ,,err ("
else:
```

return [self.value, expr, r_b]

Kôd 1.11 – klasa TokenTrigonometry

Za izraz sin x + 1) dobili bi ['sin', 'err (', ['+', 'x', '1'], ')'] što je u skladu s očekivanjima, AST bi grafički izgledao ovako (Slika 1.4):



Još bi bilo zanimljivo pogledati kako bi se parsirao izraz if {expr} then {expr} else {expr}. Od ovoga ne bi imali preveliku korist u kalkulatoru i nije nešto što se pojavljuje u konvencionalnim kalkulatorima iako bi mogli imati neku korist od, recimo, izraza 1 + if 2 –

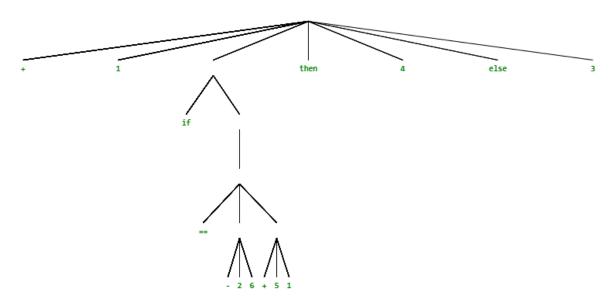
```
6 == 5 + 1 then 4 else 3. Svrha ovoga je demonstracija važnosti vrijednosti lbp i rbp. Za
ovo bi nam potrebne bile opet nove klase (Kôd 1.12, Kôd 1.13 i Kôd 1.14).
       class TokenIf(Token):
               def nud(self):
                      globa token
                      if_e = expression(self.rbp)
                      if not isinstance(token, TokenThen):
                              print(,,error then")
                              then t = ,,then
                      else:
                              then_t = token.value
                              token = lexer.__next__()
                      then_e = expression()
                      if isinstance(token, TokenElse):
                              else_t = token.value
                              token = lexer.__next__()
                              else_e = expression()
                              return [self.value, if_e, then_t, then_e, else_t, else_e]
                      else:
                              return [self.value, if_e, then_t, then_e]
                                  Kôd 1.12 – klasa TokenIf
       class TokenThen(Token):
               pass
                                Kôd 1.13 – klasa TokenThen
```

class TokenElse(Token):

Kôd 1.14 – klasa TokenElse

Primijetimo kako za token TokenElse ne radimo provjeru nego na osnovu njega upravljamo hoćemo li razrješavati then dio ili ćemo razaznati da on ne postoji.

Za naš primjer AST bi izgledao (Slika 1.5):



Slika 1.5 AST za izraz 1 + if 2 - 6 == 5 + 1 then 4 else 3

Ideja je da se krene parsirati expression nakon if koji vraća uvjet koji se ispituje i staje na then nakon kojeg ide ponovno expression sve do else i nakon toga se obrađuje else na jednak način.

U izvornom kodu rada je dodan i ternarni operator nešto jednostavnije sintakse, ali jednake značenjske vrijednosti koji nema smisla ponavljati jer je slična stvar.

1.6. Ostali operatori

U kodu su dodani i drugi klasični matematički operatori, zainteresiranog čitatelja se poziva da ih prouči. Trenutni podržani tokeni su:

11. 11	/1	•	• \
literali	ſh	TOIR	i71 \
 mulan	۱ <i>۱)</i>	ייייייייייייייייייייייייייייייייייייייי	v 1 ,

□ zbrajanje

oduzimanje
množenje
dijeljenje
potenciranje
lijeve zagrade
desne zagrade (više vrsta)
neki znakovi jednakosti
trigonometrijske funkcije (sin, cos, tan)
boolean vrijednosti
ternarni operator
if-then-else struktura
varijable

2. Prattova metoda naspram drugih

Ustanovivši da postoji široka potreba za parsiranjem napravljeni su mnogi alati i metode za generiranje parsera. Primjeri takvih alata su Yacc³ i Bison⁴. Za generičke metode kojima se ostvaruju parseri usko je vezana teorija automata. Česta ostvarenja su LR parseri.

Ovakva rješenja su adekvatna kada nije bitna optimalnost parsera ili kada je vrijeme bitan faktor. Također je moguće ostvariti puno bolje upravljanje greškama, odnosno ispis grešaka [2]. Za slučajeve kada to nije tako, razvijatelj koda ima mogućnost primijeniti Prattovu metodu parsiranja i time ostvariti puno modularniji (personaliziraniji) kod.

Postoje sličnosti između Prattovog algoritma i Shunting Yard algoritma uz razliku što drugi koristi stog umjesto rekurzije. Također je jasna sličnost između Prattove metode i algoritma "precedence climbing" gdje je logika u principu ista, ali uz drugačiju formulaciju [6]. Također postoje i neke jasne razlike između navedenih algoritma, stoga ih ne možemo smatrati identičnima [8]. Smatra se da je Dijskrta generalizirao shunting-yard metodu parsiranja koristeći samo jedan stog ili uz pomoć rekurzivnog spusta. Nakon toga Pratt ulazi "u priču" sa svojim algoritmom koji je po mnogočemu bolji od prethodne Dijskrtine metode [9].

Zanimljivo je primijetiti i sličnost s obradom prekida u operacijskim sustavima. Postoje programske implementacije koje čekaju prekidi i obrađuju ga samo u slučaju ako je veći od prekida koji se trenutno obraduje. Algoritam je rekurzivan i implementacijom podsjeća na Prattovu tehniku. Pseudo kod i njegovo objašnjenje dano je na uputama za laboratorijsku vježbu predmeta Operacijski sustava na FERu⁵.

Zanimljiva je i simbioza ovog algoritma s ostalim rješenjima.

Pokazalo se iznimno jednostavno napraviti algoritam za parsiranje matematičkih izraza koji je opisan u ovom radu, ali za ostatak jezika već je argumentirano da i nije uvijek tako.

³ http://dinosaur.compilertools.net/yacc/

⁴ https://www.gnu.org/software/bison/

⁵ http://www.zemris.fer.hr/predmeti/os/pripreme/z1b.html

Preporuka je koristiti kombinaciju parsera u smislu da se koristi glavni parser za parsiranje cijelog jezika, izuzev dijela koji služi za pridruživanje vrijednosti. Za tu svrhu ima smisla koristiti Prattov pristup jer se tada izvlači ono najbolje iz njega. Naravno, implementacija će uvijek ostati na razvijatelju i njegovim afinitetima.

Teorija automata je često u službi parsera. Različite gramatike služe za opisivanje jezika dok razni generatori generiraju lexera i parsere. Većinom su to LR parseri, njegove izvedenice i algoritmi bazirani na rekurzivnom spustu.

Programer nema potrebu znati išta iz teorije automata ili gramatike jezika kako bi shvatio kako ova metoda funkcionira što donosi nekakav značaj.

3. Primjena

Pošto smo pokazali da je najbolja primjena Prattova metoda na matematičke izraze, ona je većinom našla primjenu u tom polju. Očekivana primjena su aplikacije za rješavanje matematičkih zadataka. Aplikacija koja koristi takav pristup je Desmos⁶. U svom članku⁷ objašnjeno je zašto su prešli na Prattovu metodu i kakva im je to poboljšanja donijelo. Glavni razlog je bio upravljanje pogreškama koje generatori parsera nisu nudili. S novom implementacijom uspjeli su ostvariti manje memorijsko opterećenje i veću brzinu parsiranja. S druge strane navode i neke negativne strane poput velikog broja rekurzivnih poziva i laku mogućnost uvođenja neefikasnosti [5].

Drugi primjer primjene je ukalupljivanje u programski jezik. To je napravljeno u jeziku Natalie⁸. Pažnja je ponovno stavljena na matematičke izraze. Autor djela je također objavio video materijale koji prate razvoj jezika i ideje iza odabira Prattove metode⁹.

Vjerojatno najpoznatija implementacija je ona Douglasa Crockforda u JSLintu¹⁰. Svoj kod učinio je javnim te je moguće pogledati njegovu implementaciju¹¹ koja je podosta različita od navedenih premda postoje i drugi izvori koji koriste metodu sličnu njegovoj¹². Također je napisao i članak o svojoj implementaciji i argumentirao zašto je Prattova metoda dobra za parsiranje JavaScripta.

Pratt je u svom izvornom radu rekao da je njegova metoda već implementirana u SCRATCH-PAD-u i MACSYMA-u.

⁶ https://www.desmos.com/

⁷ https://engineering.desmos.com/articles/pratt-parser/

⁸ https://github.com/seven1m/natalie

⁹ https://natalie-lang.org/

¹⁰ https://jslint.com/

¹¹ https://github.com/douglascrockford/JSLint

¹² https://theantlrguy.atlassian.net/wiki/spaces/ANTLR3/pages/2687077/Operator+precedence+parser

4. Prednosti i nedostatci

Pokazalo se trivijalno implementirati parser za matematičke izraze te se za njihovo parsiranje ova metoda smatra vrlo pogodnom. Za cijeli jezik to bi bilo dosta kompleksnije. Manje je intuitivno u nekom jeziku odrediti prednost operatora. Dobar primjer gdje se krenu gubiti svojstva prednosti operatora i metoda kreće više ličiti klasičnom rekurzivnom spustu je kada ispred ili iza određenog tokena može doći mnogo različitih kombinacija tokena i postaje teško odrediti prednost operatora. Tada je normalno krenuti ispitivati koji se token nalazio prije trenutnog tokena te se prestaje oslanjati na prednost operatora. Apache Thrift¹³ je jedan primjer takvog jezika u kojem token Identifier može imati preko 10 različitih prefiksnih vrijednosti.

Drugi veliki nedostatak je što je metoda nepopularna i nema sličnosti s drugim metodama pa se drugi sustavi ne temelje na njemu, niti uzimaju u obzir ovakvo ostvarenje parsera. Izrazit problem može biti zadavanje gramatike u obliku koji ne vodi računa o prednosti operatora. Kod matematičkih izraza vrlo je jasno koji operator ima prednost, dok u programskim jezicima to nažalost nije slučaj. Ako je neka gramatika zadana u nepovoljnom obliku može biti lakše parsirati taj jezik koristeći metodu koja je kompatibilna s takvim načinom zadavanja gramatike. Zaključak je da se o parsiranju treba razmišljati za vrijeme definiranja jezika.

Iz prethodnog ima smisla parser temeljiti na ovoj metodi u slučaju gradnje jezika na brzinu, gdje dokumentacija (gramatika) nije previše bitna.

Ono gdje bi mogla biti veća primjena je u razvojnoj okolini gdje bi se trebala pamtiti struktura AST radi statičke analize. Takav aparat bi mogao puno bolje davati obavijesti o pogreškama od klasičnih parsera.

Ono što ovaj parser treba, kao i svaki drugi, je testiranje koje iziskuje puno resursa.

Kada je jezik zadan u BNF-u ili nekoj sličnoj strukturi vjerojatno ga nema smisla parsirati Prattovom tehnikom jer bi takva pravila trebalo prepisati u sami kod Prattovog algoritma.

¹³ https://github.com/apache/thrift/blob/master/doc/specs/idl.md

Tada bi se izgubilo vremena na toj migraciji. Možemo čak biti ekstremni i reći da je Prattov algoritam dovoljan za shvatiti sintaksu jezika.

Ono što ova metoda nudi, kao i svaki ručno pisani parser, je veća kontrola oko implementacijskih detalja s tim da ova metoda ima izrazito lak način upravljanja greškama.

Nažalost nije moguće ili je vrlo teško automatizirati izgradnju ovakve vrste parsera, ali uvijek postoji mogućnost korištenja boilerplate koda.

Zaključak

Prattova metoda izrazito je jednostavna za implementaciju unatoč pomalo konfuznoj ideji. Rekurzije su nekada vrlo zamršene i nerazumljive te su često zbog toga preskakane, no Prattova metoda nudi baš obrnuto. Nakon prihvaćanja Prattove terminologije ispada trivijalna i uklanja zamršenost u parsiranju.

Uz moć dobre obrade grešaka i brzu ručnu implementaciju nameće se kao odlična metoda za ručno pisane parsere [4]. Nedostatak je što ju je vrlo teško automatizirati za cijeli jezik.

Prattovu metodu parsiranja možemo shvatiti kao deklarativni način pisanja parsera jer je cijela kontrola upravljanja parsiranja zadana posredno. Prilikom pisanja koda dobije se dojam kao da se piše gramatika, a ne kod. To je i bila Prattova ideja kada je predstavio metodu, time je želio spojiti one koji smatraju da gramatika nije bitna pri ostvarivanju parsera i onih koji smatraju da je neophodna.

On je zamislio metodu vise kao pisanje gramatike, a manje kao pisanje programa, odnosno, uvukao je sintaksu u kod [2].

Prattova metoda danas je dosta neprihvaćena i nepoznata, a tome svjedoče malobrojni članci na internetu. Nada je da se ovim djelom pridonese popularizaciji teme.

5. Daljnji rad

Bilo bi zanimljivo promotriti strukture koje se generiraju u statičkim analizatorima koda u razvojnim okolinama. Kako se piše izvorni kod tako se gradi sintaksno stablo i to nije posebno inovativno ili zanimljivo, ali je zanimljivo kada se krenu raditi izmjene u kodu jer tada se mora zamijeniti samo dio ASTa, a ne cijelo. Argument za to da se ne gradi ponovno cijelo stablo je da se to treba obaviti brzo. Pitanje je kako bi se Prattova metoda mogla uklopiti u tu ideju i je li to uopće moguće. Za razmotriti je također frekvenciju mijenjanja određenih dijelova koda programera, nema smisla optimizirati nešto što se rijetko koristi.

Postoje neke sumnje u učinkovitost korištenja Prattove metode korištenjem objektno orijentiranog pristupa te bi imalo smisla razmotriti i druge pristupe poput npr. onog koje je Crockford koristio pri pisanju jsLint-a [10].

Literatura

- [1] Grune, D i Jacobs, C. J. H. Parsing Techniques: Introduction. New York: Springer Science+Business Media, LLC, 2008.
- [2] Pratt, Vaughan R. 1973. "Top down operator precedences". Proceedings of the 1st annual ACM SIGACTSIGPLAN symposium on Principles of programming languages, 41-51
- [3] Kladov, A., Simple but Powerful Pratt Parsing, (2020, travanj). Poveznica: https://matklad.github.io/2020/04/13/simple-but-powerful-pratt-parsing.html; pristupljeno: 3.6.2021.
- [4] Crockford, D., Top Down Operator Precedence, (2007, veljača). Poveznica: https://crockford.com/javascript/tdop/tdop.html; pristupljeno: 3. lipnja 2021.
- [5] Lantsman, D., How Desmos uses Pratt Parsers, (2018, prosinac). Poveznica: https://engineering.desmos.com/articles/pratt-parser/; pristupljeno 3. lipnja 2021.
- [6] Bendersky, E., Parsing expressions by precedence climbing, (2021, kolovoz). Poveznica: https://eli.thegreenplace.net/2012/08/02/parsing-expressions-by-precedence-climbing; pristupljeno 3. lipnja 2021.
- [7] Clarke, K., The top-down parsing of expressions https://www.antlr.org/papers/Clarke-expr-parsing-1986.pdf
- [8] Chu, A., Pratt Parsing and Precedence Climbing Are the Same Algorithm, (2016, studeni). Poveznica: http://www.oilshell.org/blog/2016/11/01.html; pristupljeno 3. lipnja 2021.
- [9] Nystrom, B., Pratt Parsers: Expression Parsing Made Easy, (2011, travanj). Poveznica: http://journal.stuffwithstuff.com/2011/03/19/pratt-parsers-expression-parsing-made-easy/; pristupljeno 3. lipnja 2021.
- [10] Jacobson, R., Making a Pratt Parser Generator, (2020, kolovoz). Poveznica: https://www.robertjacobson.dev/designing-a-pratt-parser-generator; pristupljeno 3. lipnja 2021.

Sažetak

Parsiranje od vrha prema dnu ili kraće, Prattova metoda, je rijetko poznata metoda parsiranja koja ugrađuje sintaksu jezika direktno u sam programski kod parsera. Uz to svojstvo još nudi i veliku modularnost i lako upravljanje greškama. U ovom radu prezentiran je rad Prattove metode, argumentirano kada ga ima smisla koristiti te su glavni koncepti potkrijepljeni primjerima na generičkim matematičkim izrazima.

Summary

Top down operator precedence parsing or also known as Pratt method is rarely known method of parsing in which syntax of a language is directly embedded into source code. This technic also offers great modularity and easy way of error handling. This work presents Pratt method along with arguments when to use it (what are use cases). Main concepts are presented on examples of parsing on generic mathematic expressions.

Skraćenice

LBP	Left Binding Power	lijeva vrijednost vezanja
RBP	Right Binding Power	desna vrijednost vezanja
nud	null denotation	null denotacija (prefix)
led	left denotation	lijeva denotacija (infix)
AST	Abstract Syntax Tree	apstraktno sintaksno stablo
BNF	Backus-Naur Form	Backus-Naurov oblik

Programska podrška

Za pokretanje primjera programa potreban je python 3 interpreter. Nije potrebna niti jedna nestandardna biblioteka.

Cijeli programski kod se nalazi na linku¹⁴.

Za potrebe ostvarenja lexera pri testiranju programa kao ulazi su predani stringovi tokena koji su bili odvojeni razmakom. Kao alat može poslužiti i generator lexera koji se također nalazi u git repozitoriju¹⁵.

Za program su napisani unit testovi. Ako je želja proširiti postojeći kod novim tokenima preporučuje se dopisivanje postojećih testova.

¹⁴ https://github.com/marin-jovanovic/top-down-operator-precedence/blob/master/pratt_toy/main.py

¹⁵ https://github.com/marin-jovanovic/top-down-operator-precedence/tree/master/lexer_generator